

# Линейные методы классификации

Паточенко Евгений

НИУ ВШЭ

# План занятия

- Линейные методы классификации (бинарная)
- Логистическая регрессия
- Метрики качества классификации


# Линейные методы классификации (повтор)

## Классификация

Модель машинного обучения, используемая для прогнозирования категориальной (дискретной) целевой переменной на основе одной или нескольких независимых переменных (признаков). Целевая переменная принимает конечное число классов или меток.

Может быть:

- Бинарной (классификация на два класса)  $Y = \{0,1\}$
- Многоклассовой (классификация на  $M$  непересекающихся классов)  $Y = \{1, \dots, M\}$
- Многоклассовой (классификация на  $M$  классов, которые могут пересекаться)  $Y = \{0,1\}^M$




# Линейные методы классификации (повтор)

## Классификация

Модель машинного обучения, используемая для прогнозирования категориальной (дискретной) целевой переменной на основе одной или нескольких независимых переменных (признаков). Целевая переменная принимает конечное число классов или меток.

Может быть:

- Бинарной (классификация на два класса)  $Y = \{0, 1\}$
- Многоклассовой (классификация на  $M$  непересекающихся классов)  $Y = \{1, \dots, M\}$
- Многоклассовой (классификация на  $M$  классов, которые могут пересекаться)  $Y = \{0, 1\}^M$



# Бинарная классификация

*Модель*

$$f(x, \beta) = \text{sign} \left( \sum_{i=1}^n \beta_i x_i \right)$$

# Бинарная классификация

## Модель

$$f(x, \beta) = \text{sign} \left( \sum_{i=1}^n \beta_i x_i \right)$$

Если  $\sum_{i=1}^n \beta_i x_i > 0$ , то  $\text{sign}(\sum_{i=1}^n \beta_i x_i) = +1$ , объект относится к положительному классу

Если  $\sum_{i=1}^n \beta_i x_i < 0$ , то  $\text{sign}(\sum_{i=1}^n \beta_i x_i) = -1$ , объект относится к отрицательному классу

# Бинарная классификация

## Модель

$$f(x, \beta) = \text{sign} \left( \sum_{i=1}^n \beta_i x_i \right)$$

Если  $\sum_{i=1}^n \beta_i x_i > 0$ , то  $\text{sign}(\sum_{i=1}^n \beta_i x_i) = +1$ , объект относится к положительному классу

Если  $\sum_{i=1}^n \beta_i x_i < 0$ , то  $\text{sign}(\sum_{i=1}^n \beta_i x_i) = -1$ , объект относится к отрицательному классу

$\sum_{i=1}^n \beta_i x_i = 0$  — это уравнение разделяющей границы

# Бинарная классификация

## Модель

$$f(x, \beta) = \text{sign} \left( \sum_{i=1}^n \beta_i x_i \right)$$

Если  $\sum_{i=1}^n \beta_i x_i > 0$ , то  $\text{sign}(\sum_{i=1}^n \beta_i x_i) = +1$ , объект относится к положительному классу

Если  $\sum_{i=1}^n \beta_i x_i < 0$ , то  $\text{sign}(\sum_{i=1}^n \beta_i x_i) = -1$ , объект относится к отрицательному классу

$\sum_{i=1}^n \beta_i x_i = 0$  — это уравнение разделяющей границы

В двумерном случае разделяющая граница — это прямая

В многомерном — плоскость



# Бинарная классификация

## Обучение

При обучении классификатора мы минимизируем долю ошибок:

$$Q(f, X) = \frac{1}{n} \left( \sum_{i=1}^n [f(x_i) \neq y_i] \right) \rightarrow \min,$$

где  $[f(x_i) \neq y_i] = 1$ , если предсказание на объекте неверное, иначе — 0

# Бинарная классификация

## Отступ (margin)


Отступ — степень уверенности классификатора в ответе

Обозначим отступ на  $i$ -ом объекте:

$$M_i = y_i \cdot (\beta, x_i)$$

Тогда решение задачи оптимизации при обучении классификатора эквивалентно решению задачи


$$Q(f, X) = \frac{1}{n} \left( \sum_{i=1}^n [M_i < 0] \right) \rightarrow \min$$



# Бинарная классификация

## Отступ

Чем ближе отступ к нулю, тем меньше уверенность алгоритма в ответе




# Бинарная классификация

## Функция потерь

Функция, которую минимизируем при обучении:  $Q(f, X) = \frac{1}{n} (\sum_{i=1}^n [M_i < 0]) \rightarrow \min$

Такая функция потерь называется пороговой и она разрывна, что затрудняет процесс ее минимизации




# Бинарная классификация

## Функция потерь

Для решения этой проблемы используются непрерывные или гладкие функции — верхнюю оценку пороговой функции. Они дифференцируемы и по значению больше либо равны исходной пороговой  $\Rightarrow$  автоматически минимизируют и пороговую.

Конкретную функцию выбирают в зависимости от задачи.



$V(M) = (1 - M)$  — кусочно-линейная

$H(M) = (-M)$  — кусочно-линейная

$L(M) = \log(1 + e^{-M})$  — логистическая

$Q(M) = (1 - M)^2$  — квадратичная

$S(M) = 2 \cdot (1 + e^M)^{-1}$  — сигмоидная

$E(M) = e^{-M}$  — экспоненциальная

# Логистическая регрессия

## Определение

Логистическая регрессия — это линейный классификатор, который предсказывает вероятности классов, то есть:

$f(x, \beta)$  — это вероятность того, что  $y = +1$  на объекте  $x$ :

$$f(x, \beta) = P(y = +1|x; \beta)$$

# Логистическая регрессия

## Определение


Логистическая регрессия — это линейный классификатор, который предсказывает вероятности классов, то есть:

$f(x, \beta)$  — это вероятность того, что  $y = +1$  на объекте  $x$ :

$$f(x, \beta) = P(y = +1|x; \beta)$$

Представляет собой сигмоиду:

$$f(x, \beta) = \sigma(\beta^T x) = \frac{1}{1 + e^{-\beta^T x}}$$




Напоминание

Сигмоида:  $\sigma(z) = \frac{1}{1+e^{-z}}$ ,  $\sigma(z) \in (0; 1)$

# Логистическая регрессия

*Почему сигмоида?*



Напоминание


$$\text{Сигмоида: } \sigma(z) = \frac{1}{1+e^{-z}}$$



# Логистическая регрессия

*Почему сигмоида?*

- Область допустимых значений  $\sigma(z)$ :  $[0,1]$




Напоминание

Сигмоида:  $\sigma(z) = \frac{1}{1+e^{-z}}$

# Логистическая регрессия

## Почему сигмоида?

- Область допустимых значений  $\sigma(z)$ :  $[0,1]$
- Интерпретируемая вероятность  
противоположного события  $\sigma(-z) = 1 - \sigma(z)$



Напоминание


Сигмоида:  $\sigma(z) = \frac{1}{1+e^{-z}}$

# Логистическая регрессия

## Почему сигмоида?

- Область допустимых значений  $\sigma(z)$ :  $[0,1]$
- Интерпретируемая вероятность  
противоположного события  $\sigma(-z) = 1 - \sigma(z)$
- Существование обратной функции:

$$z(s) = \ln \frac{s}{1-s}, \text{ где } s \text{ — значение сигмоиды}$$



Напоминание

$$\text{Сигмоида: } \sigma(z) = \frac{1}{1+e^{-z}}$$

# Логистическая регрессия


## Почему сигмоида?

- Область допустимых значений  $\sigma(z)$ :  $[0,1]$
- Интерпретируемая вероятность  
противоположного события  $\sigma(-z) = 1 - \sigma(z)$
- Существование обратной функции:

$$z(s) = \ln \frac{s}{1-s}, \text{ где } s \text{ — значение сигмоиды}$$

- Удобно дифференцируема:

$$\sigma'(z) = \sigma(z)(1 - \sigma(z))$$



Напоминание

$$\text{Сигмоида: } \sigma(z) = \frac{1}{1+e^{-z}}$$

# Логистическая регрессия

## Функция потерь

Квадратичную функцию для логистической регрессии использовать не получится:


- Функция примет вид  $Q(f, X) = \frac{1}{n} \sum_{i=1}^n \left( \frac{1}{1+e^{-\beta^T x}} - y \right)^2$ , а это не выпуклая функция, то есть можем не попасть в глобальный минимум при оптимизации
- На совсем неправильных предсказаниях (например, вероятность 0% для положительного объекта), штраф будет маленьким:  $(1 - 0)^2 = 1$

# Логистическая регрессия

## Функция потерь

Вместо квадратичной используется логистическая функция (log-loss):

$$\text{logloss} = -\frac{1}{n} \sum_{i=1}^n [y_i \cdot \log f(x_i, \beta) + (1 - y_i) \log(1 - f(x_i, \beta))]$$



Логистическая ошибка  
на одном объекте

# Логистическая регрессия

## Функция потерь

В отличие от квадратичной функции потерь, у логистической:

- если  $f(x, \beta) = 1$  и  $y = +1$  (алгоритм сделал верное предсказание), штраф  $L(f, y) = 0$
- если  $f(x, \beta) \rightarrow 0$ , при  $y = +1$  (т. е. предсказание неверное), штраф  $L(f, y) \rightarrow +\infty$

# Логистическая регрессия

## *Константное решение*

Пусть:

- $a$  — ответ алгоритма
- $n_1$  — объектов положительного класса
- $n_2$  — объектов отрицательного класса
- $n_1 + n_2$  — всего объектов в выборке



# Логистическая регрессия

## Константное решение

Тогда функция потерь примет вид:

$$\text{logloss} = -\frac{1}{n} \sum_{i=1}^n [y_i \cdot \log a + (1 - y_i) \log(1 - a)]$$

Так как в выборке  $n_1$  положительных и  $n_2$  отрицательных объектов, функцию можно представить как:

$$\text{logloss} = -\frac{n_1}{n} \log a - \frac{n_2}{n} \log(1 - a)$$

# Логистическая регрессия

## Константное решение

Возьмем производную по  $a$  и приравняем к 0:

$$\frac{\partial \log \text{loss}}{\partial a} = -\frac{n_1}{n} \frac{1}{a} + \frac{n_2}{n} \frac{1}{1-a} = 0$$

Выразим  $a$ :

$$a = \frac{n_1}{n}$$

Что в точности соответствует вероятности встретить объект положительного класса в выборке

# Логистическая регрессия

## Оптимизация *logloss*

Хотя *logloss* потенциально неограниченная функция, имеет смысл рассматривать значения лучше константного, поэтому принимается диапазон:

$$\text{logloss} \in \left[ 0, -\frac{n_1}{n} \log \frac{n_1}{n} - \frac{n_2}{n} \log \frac{n_2}{n} \right]$$

# Метрики качества классификации

## *Accuracy*

Accuracy — доля правильных ответов

$$accuracy(f, X) = \frac{1}{n} \sum_{i=1}^n [f(x_i) = y_i]$$

# Метрики качества классификации

## *Accuracy*

Accuracy — доля правильных ответов

$$accuracy(f, X) = \frac{1}{n} \sum_{i=1}^n [f(x_i) = y_i]$$

При сильном дисбалансе классов не отражает качество работы алгоритма

# Метрики качества классификации

## Accuracy

Пример: Нам необходимо обучить классификатор, который будет определять болен человек или здоров. В нашей обучающей выборке заболевание встречается у трех человек из тысячи. Чему будет равна accuracy **константного классификатора** классификатора, который утверждает, что все здоровы?

$$accuracy(f, X) = \frac{1}{n} \sum_{i=1}^n [f(x_i) = y_i]$$

# Метрики качества классификации

## Accuracy

Пример: Нам необходимо обучить классификатор, который будет определять болен человек или здоров. В нашей обучающей выборке заболевание встречается у трех человек из тысячи. Чему будет равна accuracy **константного классификатора** классификатора, который утверждает, что все здоровы?

$$\text{accuracy}(f, X) = \frac{1}{n} \sum_{i=1}^n [f(x_i) = y_i]$$

Accuracy составит 0,997

Можем ли мы считать, что модель хорошая?

# Метрики качества классификации

## Accuracy

Пример: Нам необходимо обучить классификатор, который будет определять болен человек или здоров. В нашей обучающей выборке заболевание встречается у трех человек из тысячи. Чему будет равна accuracy **константного классификатора** **классификатора, который утверждает, что все здоровы?**

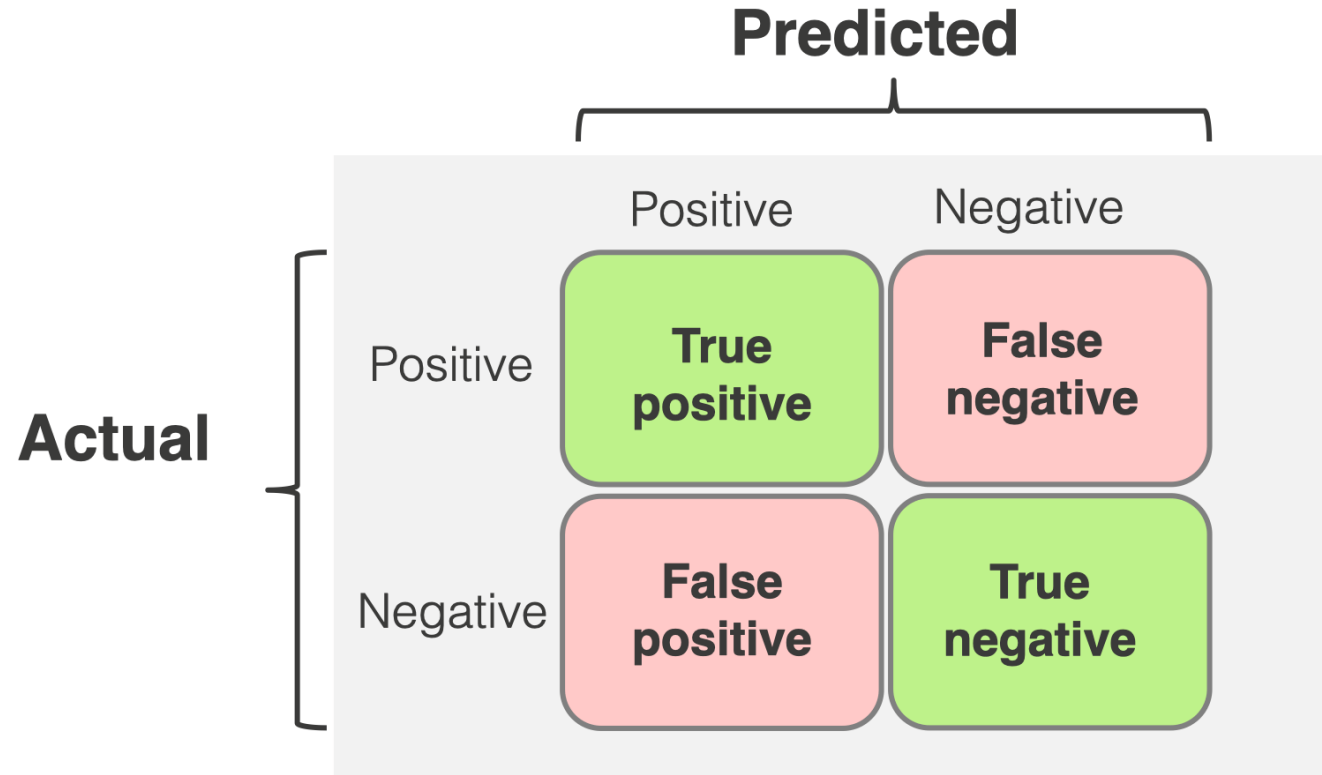
$$accuracy(f, X) = \frac{1}{n} \sum_{i=1}^n [f(x_i) = y_i]$$

Accuracy составит 0,997



# Метрики качества классификации

*Матрица ошибок (confusion matrix)*




# Метрики качества классификации

## *Матрица ошибок (confusion matrix)*


**Ошибка I рода:** истинный класс отрицательный, предсказанный класс — положительный (False Positive)

**Ошибка II рода:** истинный класс положительный, предсказанный класс — отрицательный (False Negative)

**Type I error**  
(false positive)



**Type II error**  
(false negative)



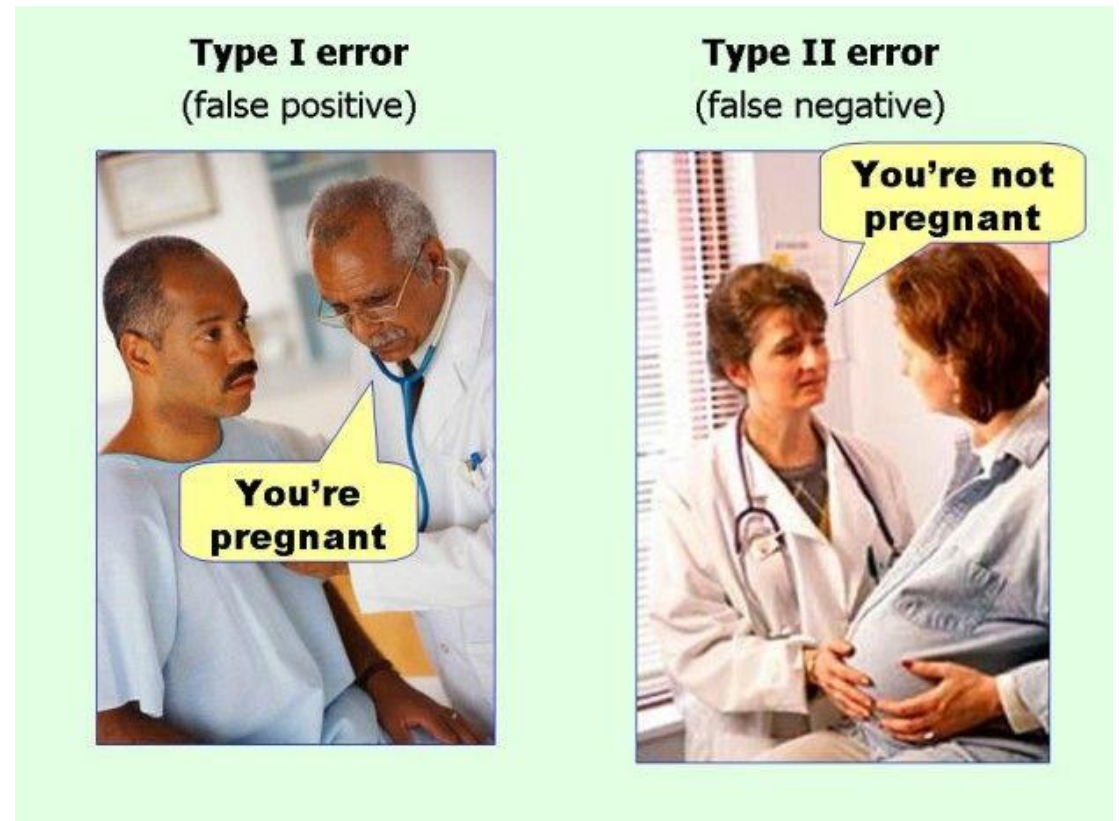
# Метрики качества классификации

## *Матрица ошибок (confusion matrix)*

**Ошибка I рода:** истинный класс отрицательный, предсказанный класс — положительный (False Positive)

**Ошибка II рода:** истинный класс положительный, предсказанный класс — отрицательный (False Negative)

**Какая ошибка более критична?**



# Метрики качества классификации

## *Precision (точность)*

Показывает, насколько можно  
доверять классификатору при  
 $f(x) = +1$

$$precision(f, X) = \frac{TP}{TP + FP}$$

# Метрики качества классификации

## *Precision (точность)*

Показывает, насколько можно  
доверять классификатору при  
 $f(x) = +1$

$$precision(f, X) = \frac{TP}{TP + FP}$$

Модель 1

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	80	20
$a(x) = -1$ Не получили кредит	20	80

Precision = ?

Модель 2

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	48	2
$a(x) = -1$ Не получили кредит	52	98

Precision = ?

# Метрики качества классификации

## Precision (точность)

Показывает, насколько можно  
доверять классификатору при  
 $f(x) = +1$

$$precision(f, X) = \frac{TP}{TP + FP}$$

Модель 1

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	80	20
$a(x) = -1$ Не получили кредит	20	80

Precision = 0,8

Модель 2

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	48	2
$a(x) = -1$ Не получили кредит	52	98

Precision = 0,96

# Метрики качества классификации

## *Recall (полнота)*

Показывает, как много  
объектов положительного  
класса находит классификатор

$$\text{recall}(f, X) = \frac{TP}{TP+FN}$$

# Метрики качества классификации

## Recall (полнота)

Показывает, как много  
объектов положительного  
класса находит классификатор

$$\text{recall}(f, X) = \frac{TP}{TP + FN}$$

Модель 1

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	80	20
$a(x) = -1$ Не получили кредит	20	80

Precision = 0,8

Recall = ?

Модель 2

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	48	2
$a(x) = -1$ Не получили кредит	52	98

Precision = 0,96

Recall = ?



# Метрики качества классификации

## Recall (полнота)

Показывает, как много  
объектов положительного  
класса находит классификатор

$$\text{recall}(f, X) = \frac{TP}{TP + FN}$$

Модель 1

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	80	20
$a(x) = -1$ Не получили кредит	20	80

Precision = 0,8

Recall = 0,8

Модель 2


	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	48	2
$a(x) = -1$ Не получили кредит	52	98

Precision = 0,96

Recall = 0,48


# Метрики качества классификации

## *Precision vs recall*




How many retrieved elements are relevant?

Precision =



How many relevant elements are retrieved?

Recall =



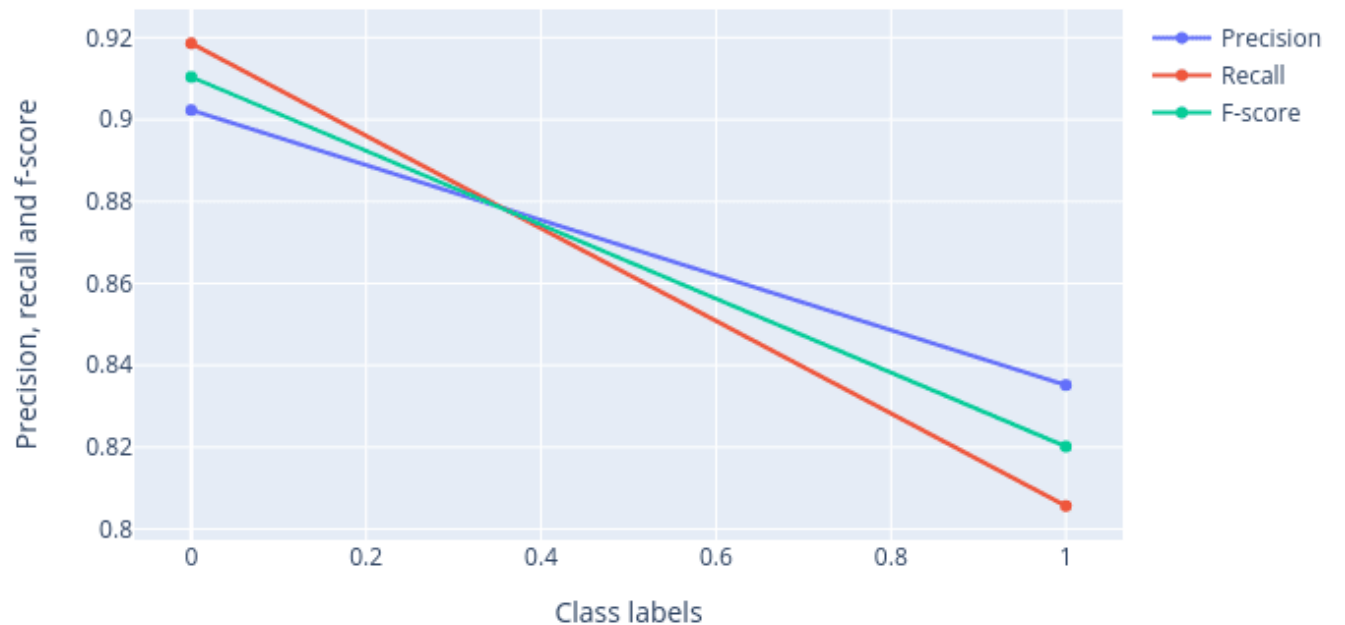
# Метрики качества классификации

## *F-мера*

Метрика, учитывающая и  
точность, и полноту

$$F(f, X) = \frac{2 \cdot \textit{Precision} \cdot \textit{Recall}}{\textit{Precision} + \textit{Recall}}$$

Precision, recall and f-score of true and predicted class labels



# Метрики качества классификации

## *Регулировка точности и полноты*

Обозначим уверенность классификатора в том, что объект  $x$  относится к классу  $+1$ , за  $p(x)$

Если  $p(x) > 0,5$ , мы относим объект к положительному классу, иначе — к отрицательному

# Метрики качества классификации

## *Регулировка точности и полноты*

Обозначим уверенность классификатора в том, что объект  $x$  относится к классу  $+1$ , за  $p(x)$

Если  $p(x) > 0,5$ , мы относим объект к положительному классу, иначе — к отрицательному

**Этот порог  $t$  можно менять в зависимости от задачи на любое число от 0 до 1**

# Метрики качества классификации

## *ROC-AUC*

Метрика, которая помогает измерить качество всего семейства классификаторов независимо от выбранного порога

AUC — Area Under ROC Curve (площадь под ROC-кривой)

# Метрики качества классификации

## ROC-AUC

Метрика, которая помогает измерить качество всего семейства классификаторов независимо от выбранного порога

AUC — Area Under ROC Curve (площадь под ROC-кривой)


Для каждого значения порога  $t$  вычислим:

$$\text{False Positive Rate (FPR)} = \frac{FP}{FP+TN} \text{ и True Positive Rate (TPR)} = \frac{TP}{TP+FN}$$

# Метрики качества классификации

## ROC-AUC

ROC-кривая — кривая, состоящая из точек с координатами (FPR, TPR) для всех возможных порогов






# Метрики качества классификации

## ROC-AUC

ROC-кривая — кривая, состоящая из точек с координатами (FPR, TPR) для всех возможных порогов




$AUC \in [0; 1]$  — площадь под ROC-кривой

# Метрики качества классификации

## ROC-AUC

ROC-кривая — кривая, состоящая из точек с координатами (FPR, TPR) для всех возможных порогов




$AUC \in [0; 1]$  — площадь под ROC-кривой

Чему равна AUC при идеальной классификации?

# Метрики качества классификации

## ROC-AUC

ROC-кривая — кривая, состоящая из точек с координатами (FPR, TPR) для всех возможных порогов



$AUC \in [0; 1]$  — площадь под ROC-кривой


Чему равна AUC при идеальной классификации?

$AUC = 1$

# Метрики качества классификации

## ROC-AUC

ROC-кривая — кривая, состоящая из точек с координатами (FPR, TPR) для всех возможных порогов



$AUC \in [0; 1]$  — площадь под ROC-кривой

Чему равна AUC при идеальной классификации?


$AUC = 1$

Чему равна AUC при случайной классификации?

# Метрики качества классификации

## ROC-AUC

ROC-кривая — кривая, состоящая из точек с координатами (FPR, TPR) для всех возможных порогов



$AUC \in [0; 1]$  — площадь под ROC-кривой

Чему равна AUC при идеальной классификации?

$AUC = 1$

Чему равна AUC при случайной классификации?

$AUC = 0,5$

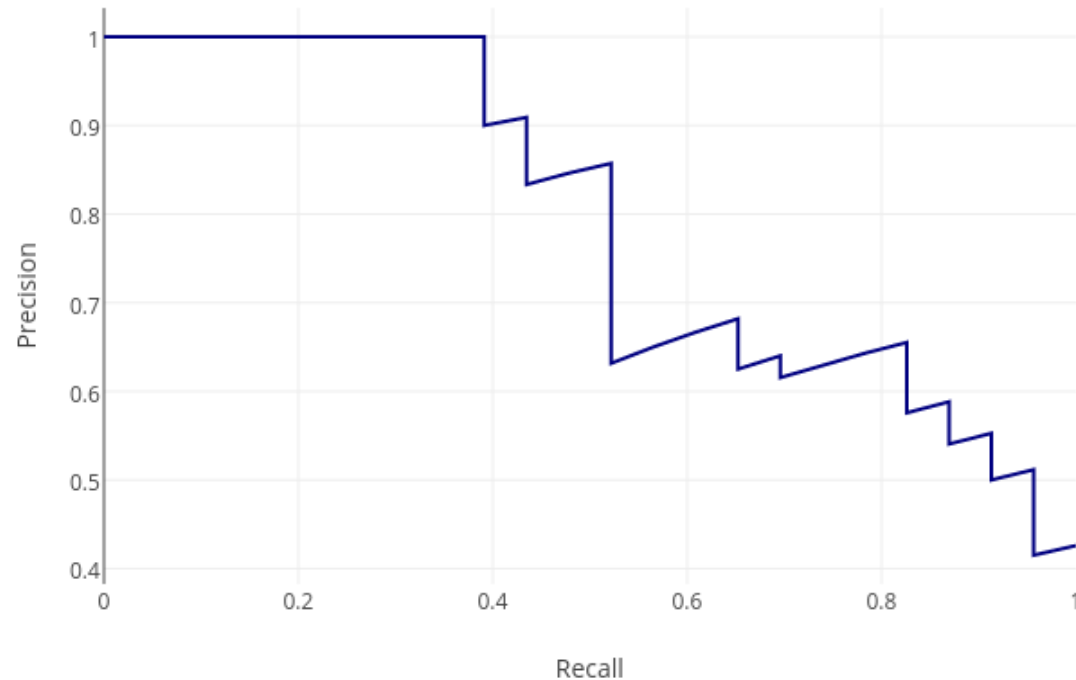
# Метрики качества классификации

## *PR-кривая*

При малой доле объектов положительного класса ROC-AUC может давать неадекватно хороший результат.

Поэтому для задач с несбалансированными классами используют precision-recall-кривую

Precision-Recall example: AUC=0.79



# Метрики качества классификации

*AUC-PR*

Площадь под PR-кривой

Precision-Recall example: AUC=0.79

